



PROYECTO EDA

DEPORTES DE MONTAÑA Y SEGURIDAD EN MADRID

Memoria Técnica

Análisis Exploratorio de Datos

Autores

Kelly Escalante

Danilo Castillo

Jorge Martínez Delgado

Bootcamp Data Science

The Bridge School

Enero 2026


INDICE

1. Introducción
2. Fuentes de datos
3. Hipótesis del estudio
4. Preparación y limpieza de datos
5. Análisis exploratorio
6. Indicadores de siniestralidad
7. Verificación de hipótesis
8. Conclusiones y recomendaciones
9. Anexos


INTRODUCCIÓN

Los deportes de montaña forman parte esencial del entramado ocioso y deportivo de la Comunidad de Madrid. Dado su emplazamiento entre cordones montañosos, la actividad en la montaña suma adeptos, año a año, haciendo de esta, una alternativa de ocio y deporte para toda la familia.


En los últimos años, el deporte de montaña ha demostrado un interés en el mismo de manera sostenida, compartiendo lugar en popularidad, y hasta a veces sobrepasando en búsquedas vía Google a la de un deporte tan difundido mundialmente como el fútbol, por ejemplo:



Este interés sostenido hace difundir más las actividades y en consecuencia se ve un aumento de actividad en montaña y por consiguiente, riesgos de accidentes en ella, como se puede ver:



Si bien la escalada (por poner un ejemplo de los tantos deportes de montaña que existen) goza de picos de búsquedas, esta actividad no se puede ver en la búsqueda de información sobre seguridad, como se puede apreciar en una comparativa entre los términos de búsqueda “montañismo” y “seguros de montaña”:



Los seguros quedan relegados con muy pocas búsquedas o movimientos en su regularidad.

La **federación madrileña de montañismo** (fmm.es) es un ente no gubernamental sin ánimo de lucro que regula, organiza y difunde los deportes de montaña, tanto así como la difusión de las actividades en la misma por fuera de las competiciones. Uno de los principales pilares de la organización es la

concientización a nivel ambiental, y la de la conciencia sobre los peligros que pueden traer estas actividades. Es desde ese punto donde se **ofrece un seguro de vida** con el que se cuenta tanto para competición o la práctica de estos deportes, con un apoyo de un seguro que costea los posibles siniestros en el entorno de montaña.

Es desde ahí donde comenzamos a perfilar nuestro problema, y trata justamente sobre la relación entre las personas federadas, que corre en torno a los 18.000 a 19.000 de año a año, y los siniestros que se producen finalmente entre sus federados.

Basados en los datos que recabamos del listado de federados del 2024 y los siniestros registrados en ese año, trataremos de avanzar en algunas conclusiones a partir de algunas hipótesis de primera mano.

Definición del problema

La Federación dispone de datos completos sobre:

- Personas federadas en 2024
- Listado de siniestros de las personas federadas durante 2024

Sin embargo, **no se ha cuantificado qué perfiles de federados concentran mayor riesgo de siniestro**, ni qué variables están más relacionadas con la gravedad de los accidentes. Esto nos lleva a consultarnos por los perfiles demográficos de los federados, sus edades, la posibilidad de que algunos estén más propensos a accidentes que otros, o que alguna de las tarjetas federativas que se ofrecen, se contratan más, debido a la cantidad de siniestros que contraen estas.

Entonces, a nivel general, podemos preguntarnos:

¿Existen diferencias significativas en la probabilidad y gravedad de los siniestros según una variable concreta del perfil del federado?

A nivel federación, esta información puede ser clave para la oferta de estos seguros de forma segmentada, ya sea para la venta, como para tenerlo en cuenta a nivel Insumo justificativo para poder negociar los distintos seguros que se ofrecen vía aseguradora externa. Partiendo de esa base, podemos acercar algunas hipótesis que a nivel general surgen desde un conocimiento general del asunto y que pueden estar sesgando las posibilidades de desarrollo tanto en venta como en cobertura para la federación. De acuerdo con esto podemos listar nuestras hipótesis:

Hipótesis A

Los federados con seguros de mayor cobertura presentan una tasa de siniestros superior al promedio del total de federados.

Hipótesis B

Los federados mayores a 35 años tienen siniestros de mayor gravedad media que los asociados a seguros básicos.

Estas hipótesis surgen a partir de conocimientos generales sobre la materia, pero tratan de buscar algunas directivas sobre las cuales podremos trabajar para encontrar información que sirva a la federación como base de posibles futuras campañas federativas, tanto así, como el conocimiento mismo de la siniestralidad de sus federados en un año en particular, para a futuro ir trazando una línea histográfica que guíe un conocimiento de la materia.

2. CONTEXTO DEL PROYECTO Y FUENTES DE DATOS

El estudio se basa en dos conjuntos de datos principales:

- **Dataset de licencias federativas**, que recoge información personal, demográfica y contractual de los federados, incluyendo variables como sexo, edad, modalidad de seguro y temporada.
- **Dataset de siniestros**, que contiene información detallada sobre los accidentes registrados, su gravedad y diversas características contextuales asociadas a cada evento.

Ambos datasets presentan estructuras heterogéneas, distintos formatos de variables y problemas habituales de calidad de datos, lo que hace imprescindible un proceso previo de limpieza y normalización antes de cualquier análisis conjunto.

4. PREPARACION Y LIMPIEZA DE DATOS

Notebook 1 – Limpieza del dataset de licencias *

* El dataset que acercamos no tiene la columna NIF, por tratarse de información sensible. Si bien el merge se hace a través de esa columna, la misma se eliminó para proteger esta información.

En el primer notebook se abordó la limpieza y preparación del dataset de licencias federativas. Las principales acciones realizadas fueron:

- Revisión de valores nulos y duplicados.
- Conversión de variables temporales a formato fecha.
- Conversión de variables numéricas con posibles inconsistencias de tipo.
- Eliminación de columnas irrelevantes para el análisis de siniestralidad.
- Análisis de cardinalidad para identificar variables con exceso de valores únicos.

Normalización de la variable sexo

Durante la inspección inicial se detectó que la variable sexo estaba codificada en origen mediante las letras “H” y “M”. En el proceso de exploración se identificó una reasignación previa inconsistente, por lo que se decidió partir nuevamente de los datos originales y aplicar una normalización semántica controlada.

Esta normalización tuvo como objetivo preservar la correcta distribución de la variable, garantizar su coherencia interna y evitar sesgos en el análisis posterior.

Creación de la variable edad

Se creó la variable edad a partir de la fecha de nacimiento con el objetivo de disponer de una variable numérica directamente interpretable y analizable. La edad permite caracterizar el perfil del federado, facilitar comparaciones entre grupos y apoyar el análisis descriptivo y estadístico, reduciendo la complejidad que supone trabajar directamente con fechas.

Notebook 2 – Limpieza del dataset de siniestros

En el segundo notebook se realizó la limpieza del dataset de siniestros, abordando:

- Conversión y homogeneización de variables temporales.

- Revisión y tratamiento de valores faltantes, priorizando variables clave para el análisis.
- Normalización básica de variables categóricas.
- Análisis de cardinalidad para evaluar la utilidad analítica de cada variable.
- Eliminación de columnas no relevantes para el estudio de siniestralidad.

El resultado fue un dataset coherente, estructurado y listo para su análisis exploratorio.


5. ANÁLISIS EXPLORATORIO DE DATOS


ANÁLISIS UNIVARIANTE

Se llevó a cabo un análisis univariante de las principales variables del estudio, observando:

- Predominio de siniestros de gravedad leve frente a otros niveles de gravedad.
- Distribución desigual de los federados por modalidad de seguro, concentrándose la mayoría en modalidades básicas.
- Distribución de la edad con mayor concentración en tramos adultos.

Este análisis permitió obtener una primera visión general del fenómeno de la siniestralidad.







ANÁLISIS BIVARIANTE

El análisis bivalente permitió explorar relaciones clave entre variables:

- Comparación entre modalidad de seguro y tasa de siniestralidad.
- Relación entre edad y gravedad del siniestro.
- Análisis de siniestros por tramos de edad.

Se observó que algunas modalidades con menor número de federados presentan tasas de siniestralidad más elevadas, lo que pone de manifiesto la importancia de analizar tasas relativas y no solo frecuencias absolutas.





6. INDICADORES DE SINIESTRALIDAD

A partir del análisis se calcularon indicadores relevantes:

- Número total de federados.
- Número total de siniestros.
- Tasa global de siniestralidad por cada 1.000 federados.
- Tasa de siniestralidad por modalidad de seguro.
- Distribución de siniestros por tramos de edad.

Estos indicadores permiten contextualizar los resultados desde una perspectiva operativa y estratégica.

7. VERIFICACIÓN DE HIPÓTESIS

Hipótesis A

Los resultados muestran que las modalidades con mayor cobertura presentan, en términos relativos, tasas de siniestralidad superiores al promedio general. Por tanto, **la Hipótesis A se considera confirmada.**

Hipótesis B


El análisis por tramos de edad indica que los federados mayores de 35 años concentran una mayor gravedad media de siniestros en comparación con los asociados a seguros básicos. En consecuencia, **la Hipótesis B se considera confirmada.**

8. CONCLUSIONES

Uno de los hallazgos más valiosos durante la obtención de los distintos gráficos que, combinando distintas variables, fue poder encontrar respuestas a las hipótesis que inauguraban el problema a resolver. Una de estas postulaba que

Los federados mayores a 35 años tienen siniestros de mayor gravedad media que los asociados a seguros básicos.

Una vez que pudimos generar una nueva columna llamada “edad”, dado que solo contábamos con la fecha de nacimiento de los federados, pudimos echar más luz y generar distintos rangos etarios que puedan arrojar datos. Es desde este cuadro:



En el que pudimos confirmar la hipótesis dado que la mayoría de los siniestros se dio en el rango de 36 a 50 años: Algo que podíamos aseverar como un conocimiento generalizado, se cristalizó en los datos recogidos por ambos data sets trabajados.

Esto puede ayudarnos para apoyar nuestras campañas federativas haciendo hincapié en estos datos y también para segmentar nuestra audiencia con distintos mensajes que puedan tocar de cerca estas preocupaciones.

Por otro lado, en la hipótesis A, ponderábamos:

Los federados con seguros de mayor cobertura presentan una tasa de siniestros superior al promedio del total de federados.

En este sentido, a la hora de indagar sobre esto, cruzando la tabla de federados, y la de siniestros, tuvimos que trabajar sobre cálculos de tasas de siniestralidad. Dado que no todos los federados tuvieron un accidente, es decir, las tablas no se relacionaban $n1 > n1$ sino que los siniestros no se distribuyen homogéneamente, avanzamos en la creación de esta tasa llegando a las siguientes conclusiones. De 18914 federados, solo se dieron 631 siniestros. Lo que nos lleva a tratar de calcular una tasa de la siguiente manera:

$$\text{Tasa} = \text{N}^\circ \text{ de federados} / \text{N}^\circ \text{ de siniestros} \times 1.000$$


Lo que nos arroja como resultado lo siguiente:

	Indicador	Valor
0	Número de federados	18914.00
1	Número de siniestros	631.00

A raíz de esto, en consiguiente, pudimos calcular esta tasa con respecto a los accidentes por tarjeta federativa. En este caso, como algunos federados contaban con más de un siniestro registrado en el año, la suma de todos los siniestros no daba igual al separarlos por tarjeta federativa, pero quedó de la siguiente manera:


	federados	siniestros	tasa_x_1000
modalidad			
D	329	26.0	79.027356
C	1513	95.0	62.789161
B	13992	481.0	34.376787
A6	128	3.0	23.437500
B6	230	4.0	17.391304

Por lo que, finalmente, para el cálculo de la tasa por tarjeta federativa arrojó lo siguiente:



En el mismo podemos ver que **la tasa de siniestros se da en mayor parte en la tarjeta federativa D que corresponde a la de la cobertura en todo el mundo en picos de hasta 7.000 metros de altura**. Esta tarjeta en particular es una de las que más cobertura ofrece, solo superada por la E, que cubre en el mismo territorio, pero en picos de más de 7000 metros. Se pueden ver las comparativas desde [la web de la federación](#).

Esto nos lleva a concluir a que la apreciación anterior, estaba en lo correcto, los seguros con más cobertura son los que más tasa de siniestralidad presentan, en este caso la D, seguido por la C con cobertura en toda Europa, y finalmente seguida por la B, que funciona de forma nacional y que actualmente es el seguro más vendido por la federación como podremos apreciar desde un punto de vista porcentual, que concentra más del 70% de los federados:



Entonces, más allá de que la tarjeta concentra la mayor cantidad de federados, los siniestros se suceden sobre todo en la modalidad D por lo que puede tomarse como insumo para futuras campañas, y segmentación para poder llegar a aquellos que practiquen deportes de montaña, por fuera del ámbito nacional.

9. ANEXO. REPOSITORIO DE NOTEBOOKS

El desarrollo completo del análisis se encuentra documentado en los siguientes notebooks alojados en GitHub:

- Notebook 1 – Limpieza de licencias
[https://github.com/jorgemd2698/EDA_Jorge_Martinez_Kelly_Escalante_Danilo_Castillo/blob/main/C%C3%B3digo/Limpieza de datos/Notebook_1 %20Limpieza y preparaci%C3%B3n de datos ListadoLicencias.ipynb](https://github.com/jorgemd2698/EDA_Jorge_Martinez_Kelly_Escalante_Danilo_Castillo/blob/main/C%C3%B3digo/Limpieza%20de%20datos/ListadoLicencias.ipynb)
- Notebook 2 – Limpieza de siniestros
[https://github.com/jorgemd2698/EDA_Jorge_Martinez_Kelly_Escalante_Danilo_Castillo/blob/main/C%C3%B3digo/Limpieza de datos/Notebook_2 Limpieza y preparaci%C3%B3n de datos ListadoPartes.ipynb](https://github.com/jorgemd2698/EDA_Jorge_Martinez_Kelly_Escalante_Danilo_Castillo/blob/main/C%C3%B3digo/Limpieza%20de%20datos/ListadoPartes.ipynb)
- Notebook 3 – Análisis exploratorio
https://github.com/jorgemd2698/EDA_Jorge_Martinez_Kelly_Escalante_Danilo_Castillo/blob/main/C%C3%B3digo/EDA/Notebook_3_EDA.ipynb