



PROYECTO EDA

DEPORTES DE MONTAÑA Y SEGURIDAD EN MADRID

Memoria Técnica

Análisis Exploratorio de Datos

Autores

Kelly Escalante

Danilo Castillo

Jorge Martínez Delgado

Bootcamp Data Science

The Bridge School

Enero 2026

INDICE

1. Introducción
2. Fuentes de datos
3. Hipótesis del estudio
4. Preparación y limpieza de datos
5. Análisis exploratorio
6. Indicadores de siniestralidad
7. Verificación de hipótesis
8. Conclusiones y recomendaciones
9. Anexos

INTRODUCCIÓN

El presente proyecto tiene como objetivo analizar la relación entre las características de los federados y la siniestralidad asociada a los seguros contratados. En particular, se pretende comprender cómo variables demográficas y contractuales influyen tanto en la frecuencia como en la gravedad de los siniestros registrados.

Desde una perspectiva de negocio, este tipo de análisis resulta clave para entidades aseguradoras y federativas, ya que permite identificar perfiles de mayor riesgo, evaluar la adecuación de los productos ofrecidos y apoyar la toma de decisiones estratégicas en materia de prevención, tarificación y diseño de coberturas.

Para ello, se ha llevado a cabo un proceso completo que abarca la preparación y limpieza de los datos, el análisis exploratorio y la verificación de hipótesis previamente planteadas. Todo el análisis se ha desarrollado utilizando técnicas de análisis de datos y visualización, garantizando la trazabilidad y reproducibilidad del proceso mediante notebooks documentados.

2. CONTEXTO DEL PROYECTO Y FUENTES DE DATOS

El estudio se basa en dos conjuntos de datos principales:

- **Dataset de licencias federativas**, que recoge información personal, demográfica y contractual de los federados, incluyendo variables como sexo, edad, modalidad de seguro y temporada.
- **Dataset de siniestros**, que contiene información detallada sobre los accidentes registrados, su gravedad y diversas características contextuales asociadas a cada evento.

Ambos datasets presentan estructuras heterogéneas, distintos formatos de variables y problemas habituales de calidad de datos, lo que hace imprescindible un proceso previo de limpieza y normalización antes de cualquier análisis conjunto.

3. HIPÓTESIS PLANTEADAS

Antes de iniciar el análisis se formularon las siguientes hipótesis:

Hipótesis A

Los federados con seguros de mayor cobertura presentan una tasa de siniestros superior al promedio del total de federados.

Hipótesis B

Los federados mayores de 35 años presentan una gravedad media de siniestros superior a la de aquellos asociados a seguros básicos.

Estas hipótesis guían el enfoque analítico desarrollado en las fases posteriores del proyecto.

4. PREPARACION Y LIMPIEZA DE DATOS

Notebook 1 – Limpieza del dataset de licencias

En el primer notebook se abordó la limpieza y preparación del dataset de licencias federativas. Las principales acciones realizadas fueron:

- Revisión de valores nulos y duplicados.
- Conversión de variables temporales a formato fecha.
- Conversión de variables numéricas con posibles inconsistencias de tipo.
- Eliminación de columnas irrelevantes para el análisis de siniestralidad.
- Análisis de cardinalidad para identificar variables con exceso de valores únicos.

Normalización de la variable sexo

Durante la inspección inicial se detectó que la variable sexo estaba codificada en origen mediante las letras “H” y “M”. En el proceso de exploración se identificó una reasignación previa inconsistente, por lo que se decidió partir nuevamente de los datos originales y aplicar una normalización semántica controlada.

Esta normalización tuvo como objetivo preservar la correcta distribución de la variable, garantizar su coherencia interna y evitar sesgos en el análisis posterior.

Creación de la variable edad

Se creó la variable edad a partir de la fecha de nacimiento con el objetivo de disponer de una variable numérica directamente interpretable y analizable. La edad permite caracterizar el perfil del federado, facilitar comparaciones entre grupos y apoyar el análisis descriptivo y estadístico, reduciendo la complejidad que supone trabajar directamente con fechas.

Notebook 2 – Limpieza del dataset de siniestros

En el segundo notebook se realizó la limpieza del dataset de siniestros, abordando:

- Conversión y homogeneización de variables temporales.
- Revisión y tratamiento de valores faltantes, priorizando variables clave para el análisis.
- Normalización básica de variables categóricas.
- Análisis de cardinalidad para evaluar la utilidad analítica de cada variable.
- Eliminación de columnas no relevantes para el estudio de siniestralidad.

El resultado fue un dataset coherente, estructurado y listo para su análisis exploratorio.



5. ANÁLISIS EXPLORATORIO DE DATOS

ANÁLISIS UNIVARIANTE

Se llevó a cabo un análisis univariante de las principales variables del estudio, observando:

- Predominio de siniestros de gravedad leve frente a otros niveles de gravedad.
- Distribución desigual de los federados por modalidad de seguro, concentrándose la mayoría en modalidades básicas.
- Distribución de la edad con mayor concentración en tramos adultos.

Este análisis permitió obtener una primera visión general del fenómeno de la siniestralidad.




ANÁLISIS BIVARIANTE

El análisis bivalente permitió explorar relaciones clave entre variables:

- Comparación entre modalidad de seguro y tasa de siniestralidad.
- Relación entre edad y gravedad del siniestro.
- Análisis de siniestros por tramos de edad.

Se observó que algunas modalidades con menor número de federados presentan tasas de siniestralidad más elevadas, lo que pone de manifiesto la importancia de analizar tasas relativas y no solo frecuencias absolutas.



6. INDICADORES DE SINIESTRALIDAD

A partir del análisis se calcularon indicadores relevantes:

- Número total de federados.
- Número total de siniestros.
- Tasa global de siniestralidad por cada 1.000 federados.
- Tasa de siniestralidad por modalidad de seguro.
- Distribución de siniestros por tramos de edad.

Estos indicadores permiten contextualizar los resultados desde una perspectiva operativa y estratégica.

7. VERIFICACIÓN DE HIPÓTESIS

Hipótesis A

Los resultados muestran que las modalidades con mayor cobertura presentan, en términos relativos, tasas de siniestralidad superiores al promedio general. Por tanto, **la Hipótesis A se considera confirmada.**

Hipótesis B


El análisis por tramos de edad indica que los federados mayores de 35 años concentran una mayor gravedad media de siniestros en comparación con los asociados a seguros básicos. En consecuencia, **la Hipótesis B se considera confirmada.**

8. CONCLUSIONES

Uno de los hallazgos más valiosos durante la obtención de los distintos gráficos que, combinando distintas variables, fue poder encontrar respuestas a las hipótesis que inauguraban el problema a resolver. Una de estas postulaba que

Los federados mayores a 35 años tienen siniestros de mayor gravedad media que los asociados a seguros básicos.

Una vez que pudimos generar una nueva columna llamada “edad”, dado que solo contábamos con la fecha de nacimiento de los federados, pudimos echar más luz y generar distintos rangos etarios que puedan arrojar datos. Es desde este cuadro:



En el que pudimos confirmar la hipótesis dado que la mayoría de los siniestros se dio en el rango de 36 a 50 años: Algo que podíamos aseverar como un conocimiento generalizado, se cristalizó en los datos recogidos por ambos data sets trabajados.

Esto puede ayudarnos para apoyar nuestras campañas federativas haciendo hincapié en estos datos y también para segmentar nuestra audiencia con distintos mensajes que puedan tocar de cerca estas preocupaciones.

Por otro lado, en la hipótesis A, ponderábamos:

Los federados con seguros de mayor cobertura presentan una tasa de siniestros superior al promedio del total de federados.

En este sentido, a la hora de indagar sobre esto, cruzando la tabla de federados, y la de siniestros, tuvimos que trabajar sobre cálculos de tasas de siniestralidad. Dado que no todos los federados tuvieron un accidente, es decir, las tablas no se relacionaban $n1 > n1$ sino que los siniestros no se distribuyen homogéneamente, avanzamos en la creación de esta tasa llegando a las siguientes conclusiones. De 18914 federados, solo se dieron 631 siniestros. Lo que nos lleva a tratar de calcular una tasa de la siguiente manera:

$$\text{Tasa} = \text{N}^\circ \text{ de federados} / \text{N}^\circ \text{ de siniestros} \times 1.000$$

Lo que nos arroja como resultado lo siguiente:

	Indicador	Valor
0	Número de federados	18914.00
1	Número de siniestros	631.00
2	Tasa de siniestralidad (por 1.000)	33.36


	federados	siniestros	tasa_x_1000
modalidad			
D	329	26.0	79.027356
C	1513	95.0	62.789161
B	13992	481.0	34.376787
A6	128	3.0	23.437500
B6	230	4.0	17.391304

Por lo que, finalmente, para el cálculo de la tasa por tarjeta federativa arrojó lo siguiente:



En el mismo podemos ver que **la tasa de siniestros se da en mayor parte en la tarjeta federativa D que corresponde a la de la cobertura en todo el mundo en picos de hasta 7.000 metros de altura**. Esta tarjeta en particular es una de las que más cobertura ofrece, solo superada por la E, que cubre en el mismo territorio, pero en picos de más de 7000 metros. Se pueden ver las comparativas desde [la web de la federación](#).

Esto nos lleva a concluir a que la apreciación anterior, estaba en lo correcto, los seguros con más cobertura son los que más tasa de siniestralidad presentan, en este caso la D, seguido por la C con cobertura en toda Europa, y finalmente seguida por la B, que funciona de forma nacional y que actualmente es el seguro más vendido por la federación como podremos apreciar desde un punto de vista porcentual, que concentra más del 70% de los federados:



Entonces, más allá de que la tarjeta concentra la mayor cantidad de federados, los siniestros se suceden sobre todo en la modalidad D por lo que puede tomarse como insumo para futuras campañas, y segmentación para poder llegar a aquellos que practiquen deportes de montaña, por fuera del ámbito nacional.

9. ANEXO. REPOSITORIO DE NOTEBOOKS

El desarrollo completo del análisis se encuentra documentado en los siguientes notebooks alojados en GitHub:

- Notebook 1 – Limpieza de licencias
[https://github.com/jorgemd2698/EDA_Jorge_Martinez_Kelly_Escalante_Danilo_Castillo/blob/main/C%C3%B3digo/Limpieza de datos/Notebook_1 %20Limpieza y preparaci%C3%B3n de datos ListadoLicencias.ipynb](https://github.com/jorgemd2698/EDA_Jorge_Martinez_Kelly_Escalante_Danilo_Castillo/blob/main/C%C3%B3digo/Limpieza%20de%20datos/ListadoLicencias.ipynb)
- Notebook 2 – Limpieza de siniestros
[https://github.com/jorgemd2698/EDA_Jorge_Martinez_Kelly_Escalante_Danilo_Castillo/blob/main/C%C3%B3digo/Limpieza de datos/Notebook_2 Limpieza y preparaci%C3%B3n de datos ListadoPartes.ipynb](https://github.com/jorgemd2698/EDA_Jorge_Martinez_Kelly_Escalante_Danilo_Castillo/blob/main/C%C3%B3digo/Limpieza%20de%20datos/ListadoPartes.ipynb)
- Notebook 3 – Análisis exploratorio
[https://github.com/jorgemd2698/EDA_Jorge_Martinez_Kelly_Escalante_Danilo_Castillo/blob/main/C%C3%B3digo/EDA/Notebook_3 EDA.ipynb](https://github.com/jorgemd2698/EDA_Jorge_Martinez_Kelly_Escalante_Danilo_Castillo/blob/main/C%C3%B3digo/EDA/Notebook_3_EDA.ipynb)